

PROYECTO FINAL - GOOGLE CLOUD PLATFORM

Pipeline Inteligente de Clasificación de Gastos

Solución Serverless y Event-Driven con Visión Artificial y Analítica Columnar

Repositorio GitHub con código e IaC: <https://github.com/extdiegorenteria-ai/gcp-expense-classifier>


Arquitectura: 100% Serverless en GCP (Storage, Cloud Functions, Vertex AI, BigQuery, Looker Studio)

1. Identificación del Proceso a Automatizar

El control de gastos personales y la rendición de cuentas de negocios suele depender de la revisión manual de tickets, boletas y facturas físicas o digitales. Este proceso manual adolece de fricciones recurrentes: pérdida de comprobantes, errores humanos de transcripción en hojas de cálculo y demoras de semanas para conocer el estado financiero real.

Objetivo de la solución: Implementar un pipeline desatendido donde el usuario únicamente sube fotos o documentos PDF de comprobantes a un bucket de almacenamiento. Automáticamente, mediante modelos de Inteligencia Artificial multimodal en la nube, se extraen los campos clave estructurados (comercio, fecha, categoría, montos e impuestos) y se persisten en un almacén analítico para visualización en tiempo real.

2. Diagrama de Arquitectura de la Solución



3. Servicios de Google Cloud Utilizados

Servicio de GCP	Capa de la Arquitectura	Rol y Justificación Técnica
Cloud Storage (GCS)	Ingesta (*Landing Zone*)	Almacenamiento de objetos seguro y duradero para los recibos crudos. Emite eventos a nivel de objeto para activar el flujo.
Cloud Functions (2nd Gen)	Cómputo Serverless	Ejecución de lógica basada en microcontenedores sobre Cloud Run. Escala a cero, reduciendo costos a cero en reposo.
Vertex AI (Gemini 2.5 Flash)	Inferencia Multimodal	Extracción precisa de datos textuales y numéricos desde imágenes o PDFs, asegurando esquema estricto (JSON Schema).
BigQuery	Data Warehouse Analítico	Base de datos analítica columnar. Se particiona por fecha de transacción para optimizar tiempos de consulta y minimizar costos.
Looker Studio	Visualización / BI	Dashboards dinámicos interactivos para control presupuestal, desglose por categorías y tendencias de gasto.
Cloud IAM	Seguridad y Gobierno	Service Account con privilegios mínimos (BigQuery Data Editor, Vertex AI User, Storage Object Viewer).

4. Descripción Paso a Paso de la Solución

Paso 1: Carga de Comprobante en Cloud Storage

El usuario sube el archivo (imagen JPG/PNG o documento PDF) al bucket `gs://gcp-expense-darv-6849-gastos-raw/inbox/`. El bucket cuenta con reglas de ciclo de vida para optimizar costos de almacenamiento a largo plazo.

Paso 2: Disparo de Evento mediante Eventarc

La finalización de la carga dispara una notificación

`google.cloud.storage.object.v1.finalized`. Eventarc enruta este evento de inmediato a la Cloud Function de 2da generación.

Paso 3: Extracción Inteligente con Vertex AI

La Cloud Function toma la referencia URI del archivo y realiza una consulta multimodal a `gemini-2.5-flash` con *Structured Outputs* activado. El modelo extrae con rigor la fecha, el comercio emisor, la categoría presupuestal, la moneda, el importe total y los impuestos.

Paso 4: Inserción Streaming en BigQuery

La función valida el JSON estructurado, genera un identificador único (UUID) y realiza un *streaming insert* directo en la tabla `gastos.gastos_clasificados`, asociando además la URI de auditoría del archivo original.

Paso 5: Visualización y Toma de Decisiones en Looker Studio

A través del conector nativo de BigQuery, Looker Studio presenta un reporte financiero en tiempo real que clasifica gastos por categorías, compara contra presupuestos mensuales y detecta picos inusuales de gasto.

5. Infraestructura como Código Modular (Terraform)

Toda la infraestructura se diseñó siguiendo el estándar de producción mediante separación modular de responsabilidades:

- `main.tf` & `services.tf` : Providers y activación de APIs de GCP.
- `storage.tf` & `bigquery.tf` : Landing zone en GCS y Data Warehouse particionado.
- `iam.tf` : Principio de menor privilegio para la Service Account y Eventarc.
- `function.tf` : Definición serverless de Cloud Functions v2 y Eventarc.
- `variables.tf` & `outputs.tf` : Parametrización y exportación de endpoints.

6. Cumplimiento del Free Tier y Costos

La arquitectura fue concebida para no incurrir en gastos fijos. Al ser 100% serverless, no consume recursos en reposo:

- **Almacenamiento:** Dentro de los 5 GB mensuales del Free Tier de Cloud Storage.
- **Cómputo:** Las primeras 2 millones de ejecuciones mensuales de Cloud Functions son gratuitas.
- **Consultas:** BigQuery incluye 10 GB de almacenamiento y 1 TB de procesamiento de consultas gratuito mensual.
- **Inferencia:** Gemini 2.5 Flash en Vertex AI tiene un coste inferior a \$0.05 USD por cada 500 comprobantes procesados, cubierto por los créditos iniciales de Google Cloud.

7. Evidencia de Ejecución en Producción (Prueba E2E)

Se ejecutó una prueba de extremo a extremo subiendo el comprobante `ticket_restaurante_001.jpg` a Cloud Storage. El flujo se activó reactivamente mediante Eventarc y persistió exitosamente en BigQuery:

Atributo	Valor Extraído por el Modelo y Almacenado en BigQuery
Fecha de Gasto	2026-09-18
Comercio	RESTAURANTE EL BUEN SABOR
Categoría Asignada	Alimentacion
Moneda	PEN
Monto Total Facturado	S/ 45.00
Impuesto Desglosado (IGV 18%)	S/ 6.86
Confianza del Modelo	0.95 (95%)
URI de Auditoría en GCS	gs://gcp-expense-darv-6849-gastos-raw/inbox/ticket_restaurante_001.jpg